

Métodos basados en unidades de medida inercial para la detección en tiempo real de eventos de conducción en bicicleta:

revisión sistemática orientada a sistemas IoT de seguridad

Manuel Gómez Domingo, 819062

Resumen—La detección en tiempo real de eventos de conducción en bicicleta es relevante para la seguridad ciclista, la monitorización de la movilidad urbana y el diseño de sistemas ligeros de Internet de las Cosas (IoT) para aviso y asistencia. Este trabajo revisa métodos basados en unidades de medida inercial (IMU) para detectar eventos como frenadas, caídas, incidentes de casi colisión (*near-miss*), anomalías del firme y maniobras de conducción. Se realizó una revisión sistemática de la literatura siguiendo un protocolo guiado por PICOS y una lógica de reporte PRISMA. Las búsquedas en IEEE Xplore y Google Scholar identificaron 643 registros; tras el cribado y la evaluación a texto completo, se incluyeron 17 estudios en la síntesis final. La literatura revisada muestra que el campo está dominado por el sensado basado en *smartphones*, las IMU montadas o embebidas en la bicicleta y un conjunto más reducido de enfoques corporales o montados en casco. Las familias algorítmicas más recurrentes son el aprendizaje profundo aplicado a series temporales de señales IMU, las máquinas de vectores soporte y los métodos heurísticos o basados en umbrales. Los resultados reportados son heterogéneos y dependen del tipo de evento, la posición del sensor, el protocolo experimental y la métrica utilizada, por lo que no deben interpretarse como una comparación directa entre estudios. En conjunto, la respuesta a la pregunta de investigación es que los enfoques más adecuados para un despliegue IoT práctico son las IMU montadas o embebidas en la bicicleta combinadas con algoritmos ligeros basados en ventanas temporales de aceleración y giro, o con clasificadores compactos basados en características extraídas de la señal IMU. Estos enfoques ofrecen el mejor equilibrio entre capacidad de clasificación, rapidez de respuesta, fiabilidad de alerta y viabilidad práctica. No obstante, persisten limitaciones en tamaño de los *datasets*, generalización entre bicicletas, reproducibilidad, falsas alarmas en circulación real y ausencia de un conjunto de referencia común que cubra múltiples tipos de evento en condiciones realistas de circulación.

Palabras clave—seguridad ciclista, reconocimiento del comportamiento del ciclista, detección de eventos, IMU, Internet de las Cosas, detección de *near-miss*, sensado en tiempo real

I. INTRODUCCIÓN

EL uso de la bicicleta se promueve cada vez más como una forma de transporte sostenible y saludable, pero su adopción a gran escala sigue estando fuertemente condicionada por la seguridad real y percibida. Esto genera la necesidad de sistemas de sensado capaces de reconocer en tiempo real eventos de conducción relevantes o potencialmente peligrosos, especialmente en entornos urbanos donde los ciclistas interactúan con vehículos, peatones, pavimentos irregulares y condiciones de tráfico cambiantes. En este contexto, las unidades de medida inercial (IMU), compuestas principalmente por

acelerómetros y giróscopos, resultan especialmente atractivas por su bajo coste, su amplia disponibilidad en smartphones y electrónica embebida y su compatibilidad con despliegues IoT de bajo consumo.

La motivación específica de esta revisión es el diseño futuro de un prototipo basado en Arduino Nano 33 BLE, orientado a detectar eventos sobre la bicicleta y activar una alarma sencilla cuando ocurra un evento severo compatible con caída o accidente. Aunque el objetivo final de implementación es modesto, el estado del arte debe plantearse de forma más amplia. Por ello, resulta útil revisar no solo trabajos centrados en caída o accidente, sino también estudios sobre detección de frenada, predicción de maniobras, detección de *near-miss* y reconocimiento de anomalías del firme, ya que estas familias de eventos comparten principios de sensado, etapas de pre-procesado y estrategias de clasificación. Estudios tempranos exploraron la detección de accidentes tipo *eCall* para ciclistas con smartphone [1], mientras que trabajos posteriores ampliaron el foco hacia reconocimiento de comportamiento ciclista [2], monitorización de conducción peligrosa [3], detección de accidentes con sensores MARG [4] y sensado embebido en bicicletas compartidas [5], [6]. Estudios más recientes también han mostrado el potencial del aprendizaje profundo temporal para predicción de maniobras y análisis de *near-miss* [7], [8], [9], [10].

Sin embargo, este conjunto de trabajos es muy heterogéneo. Las taxonomías de eventos difieren entre estudios; los sensores se colocan en el ciclista, en el manillar, en el cuadro o en componentes específicos de la bicicleta; y el rendimiento se reporta mediante métricas no siempre comparables, como exactitud, F1-score, AUC, correlación o tasa de falsos positivos. Además, algunos artículos se centran en casos de uso muy concretos pero prácticos, mientras que otros priorizan la novedad algorítmica sin abordar restricciones reales de despliegue. Por ello, se hace necesaria una síntesis estructurada que permita responder a la pregunta central de esta revisión: *¿qué métodos basados en sensores inerciales (IMU) son más adecuados para la detección en tiempo real de eventos de conducción en bicicleta, considerando su capacidad de clasificación, rapidez de respuesta, fiabilidad de alerta y viabilidad práctica en sistemas IoT?*

Este artículo responde a esa pregunta mediante una revisión sistemática de 17 estudios incluidos. La Sección II presenta la metodología de revisión y el proceso de selección basado en PRISMA. La Sección III sintetiza los trabajos incluidos

Tabla I
DEFINICIÓN OPERATIVA DE PICOS.

PICOS	Definición aplicada
P	Ciclistas en movilidad real o experimental sobre bicicleta, en entorno real o controlado con datos reales.
I	IMU, acelerómetro, giróscopo o sensor MARG como modalidad principal de detección.
C	Otros métodos basados en IMU o baselines cuantitativamente comparables.
O	Exactitud, F1-score, AUC, sensibilidad, especificidad, latencia o falsas alarmas.
S	Validación experimental con datos reales o realistas; se excluyen simulaciones puras y propuestas sin validación.

por configuración de sensado y por familia de eventos. La Sección IV discute la solidez metodológica, las limitaciones, la transferibilidad a un prototipo de seguridad ciclista basado en Arduino y los vacíos de investigación abiertos. Finalmente, la Sección V resume las conclusiones principales.

II. METODOLOGÍA

La revisión siguió un flujo de trabajo de revisión sistemática adaptado a ingeniería de sensores. La pregunta de investigación se formuló mediante una estructura PICOS en la que la población/problema fue el uso de la bicicleta en contextos reales o realistas de circulación, la intervención fue la detección de eventos basada en IMU con acelerómetro y/o giróscopo como modalidad principal, el comparador fueron otros métodos basados en IMU o alternativas cuantitativamente comparables, los *outcomes* fueron métricas cuantitativas estándar de detección o clasificación junto con latencia o comportamiento frente a falsas alarmas cuando estaba disponible, y el diseño de estudio exigió validación experimental con datos reales relacionados con bicicleta. En la síntesis no se trataron todas las métricas como equivalentes: la exactitud mide la proporción global de clasificaciones correctas, el F1-score resume el equilibrio entre precisión y sensibilidad, y el AUC-ROC evalúa la capacidad discriminativa del modelo para separar clases positivas y negativas bajo distintos umbrales de decisión. Se excluyeron revisiones, propuestas puramente conceptuales, estudios basados solo en simulación y trabajos sin evidencia cuantitativa utilizable.

La Tabla I resume la traducción operativa del marco PICOS utilizada en el protocolo.

Las búsquedas se realizaron en IEEE Xplore y Google Scholar. La cadena base empleada en IEEE Xplore fue:

```
(bicycle OR cyclist OR cycling OR e-bike)
AND (IMU OR inertial measurement unit
OR accelerometer OR gyroscope OR MARG
OR inertial sensor) AND (event detection
OR braking OR brake OR fall OR crash OR
accident OR collision OR near miss OR bump
OR curb OR pothole OR roughness OR maneuver
OR behaviour)
```

En Google Scholar se utilizó una cadena equivalente, más flexible, con los mismos tres bloques conceptuales: dominio ciclista, sensado inercial y familias de eventos. La búsqueda inicial produjo 643 registros en total (11 procedentes de IEEE Xplore y 632 de Google Scholar). Dado el carácter muy amplio de Google Scholar, antes del cribado formal se

realizó una depuración manual coherente con PICOS para eliminar resultados manifiestamente fuera de foco, documentos secundarios, registros no evaluables y resultados irrelevantes por título o fuente. Esa depuración explica los 608 registros eliminados antes del cribado formal que aparecen en PRISMA como *records removed for other reasons*. Tras esa depuración, 35 registros entraron en el cribado formal.

Los criterios de inclusión operativos fueron los siguientes: 1) estudio primario sobre bicicleta o ciclismo; 2) uso de IMU, acelerómetro, giróscopo o MARG como sensor principal; 3) detección o clasificación de un evento ciclista relevante o transferible; 4) presencia de resultados cuantitativos interpretables; y 5) validación experimental con datos reales o realistas. Los criterios de exclusión operativos fueron: 1) fuera del dominio bicicleta/ciclismo; 2) tecnología principal distinta de IMU; 3) revisión secundaria o propuesta conceptual; 4) ausencia de métricas estándar o de validación usable; y 5) irrelevancia confirmada tras lectura completa.

Los códigos empleados en el proceso de cribado PRISMA fueron los siguientes: WF indica registros fuera del alcance temático de la revisión; SER, revisiones sistemáticas o documentos secundarios; NR-1, registros no relevantes tras la lectura de título y resumen; NR-2, registros no relevantes tras la lectura del texto completo; LR-2, estudios con evidencia comparativa insuficiente; y LR-3, estudios con métricas no estándar, incompletas o no utilizables para la síntesis cuantitativa.

En el cribado por título y resumen se excluyeron 11 registros (7 con código WF, 2 con código NR-1 y 2 revisiones sistemáticas etiquetadas como SER). Posteriormente, se evaluaron 24 textos completos y se excluyeron 7 en esta etapa (2 NR-2, 2 LR-2 y 3 LR-3). La síntesis final quedó formada por 17 estudios. El flujo de selección se resume en la Fig. 1.

Además, la calidad metodológica de los estudios incluidos se evaluó mediante ocho ítems: validación con datos reales, muestra suficiente, métricas estándar, existencia de baseline, reproducibilidad, limitaciones declaradas, generalización y declaración de conflictos de interés. Esta evaluación se utiliza después para ponderar la fuerza de la evidencia en la discusión.

III. RESULTADOS

III-A. Visión general de la literatura incluida

El corpus final abarca de 2013 a 2025 e incluye cinco grandes familias de eventos: detección de accidente o caída, reconocimiento de anomalías del firme, detección de frenada, predicción de maniobras o reconocimiento de comportamiento y detección de *near-miss*. En la capa de sensado predominan claramente los *smartphones* montados en el ciclista o en la bicicleta [1], [2], [3], [11], [12], [13], [14]. Un segundo grupo utiliza IMU montadas en la bicicleta, embebidas o integradas en componentes como candados o cuadros [5], [6], [8], [15], [16]. Finalmente, un grupo más pequeño pero metodológicamente relevante emplea IMU montadas en casco o sistemas *wearable* [7].

En los 17 artículos, las familias algorítmicas más frecuentes fueron el aprendizaje profundo temporal, las máquinas de vectores soporte y los enfoques heurísticos o basados en umbrales.




Figura 1. Diagrama de flujo PRISMA 2020 para la identificación, cribado, evaluación de elegibilidad e inclusión final de estudios.

El rendimiento reportado es heterogéneo, ya que los estudios evalúan eventos, posiciones de sensor, *datasets* y métricas diferentes. En tareas de reconocimiento de comportamiento ciclista se observan F1-score elevados, habitualmente en torno a 0.90–0.965 [2], [14], [16], mientras que los estudios de caída o eventos de conducción en escenarios controlados alcanzan exactitudes cercanas o superiores al 99 % [5], [17]. Por el contrario, los trabajos centrados en anomalías del firme o detección de *near-miss* emplean métricas y protocolos menos directamente comparables, como exactitud global, correlación o AUC-ROC [9], [10], [11], [13]. Por ello, estos valores deben interpretarse como evidencia del potencial de las IMU, pero no como una clasificación directa de qué método es universalmente superior.

III-B. Sistemas basados en *smartphone*

Los sistemas basados en *smartphone* constituyen la clase de soluciones más accesible, ya que aprovechan sensores ya presentes en dispositivos de uso común y no requieren instalar instrumentación específica en la bicicleta. Dentro de este grupo pueden distinguirse tres líneas principales: detección de accidente o caída, reconocimiento de anomalías del firme y detección de comportamientos de conducción.

En primer lugar, varios trabajos se orientan a la detección de accidente o caída. Candefjord *et al.* propusieron una solución de tipo *eCall* para ciclistas basada en *smartphone*, utilizando GPS, acelerómetro y giróscopo. Su algoritmo detectó los 6 accidentes simulados y no produjo falsos positivos durante más de cinco horas de ciclismo normal [1]. Posteriormente, Tabei *et al.* emplearon un módulo MARG montado en el manillar

y combinaron PCA con SVM para detectar accidentes por caída, alcanzando un 95.2 % de exactitud [4]. Alcaide *et al.* también abordaron la detección de caídas con una arquitectura IoT basada en sensor MARG, PCA y SVM cuadrática, e informaron de un 99.05 % de exactitud junto con envío de alertas SMS [17]. Estos estudios son relevantes para una lógica de alarma ante accidente, aunque comparten una limitación importante: la mayoría de eventos positivos proceden de caídas o accidentes simulados, no de accidentes reales en circulación natural.

En segundo lugar, los *smartphones* se han utilizado para detectar irregularidades del firme y estimar la calidad de la superficie. Kobana *et al.* combinaron ICA, FFT y reglas basadas en umbrales para clasificar daños del pavimento a partir de un teléfono situado en el bolsillo lateral del ciclista, con un 70.0 % de exactitud global [11]. Hoffmann *et al.* emplearon teléfonos montados en la bicicleta para analizar la calidad del firme y detectar irregularidades puntuales; la exactitud aproximada del 97 % corresponde específicamente a la detección de baches o resaltos, mientras que la clasificación global de la calidad del firme es menos directamente comparable [12]. Zang *et al.* propusieron un método para estimar la rugosidad mediante el índice IRI y detectar baches o elevaciones de la calzada con GPS y acelerómetro en un *smartphone* montado en bicicleta, obteniendo una correlación fuerte con instrumentación profesional ($r = 0.893$) [13]. Estos trabajos son útiles para reconocer bordillos, baches, resaltos o rugosidad, aunque su transferencia directa a una alarma de accidente requiere precaución, ya que el objetivo principal no es detectar una caída sino caracterizar el estado del firme.

En tercer lugar, varios estudios se centran en el reconocimiento de comportamiento ciclista o patrones de conducción potencialmente peligrosos. El sistema BikeMate, propuesto por Gu *et al.*, detecta zigzagado en el carril, pedaleo de pie y circulación en sentido contrario mediante IMU y GPS de *smartphone*, con un 86.8 % de exactitud para comportamientos de conducción y un 90.0 % para circulación en sentido contrario [3]. Usami *et al.* abordaron cuatro estados básicos —parada, avance recto, giro a la izquierda y giro a la derecha— usando acelerómetro y giróscopo de un teléfono montado en el manillar, y alcanzaron un F1-score cercano a 0.9 con un clasificador Random Forest [2]. El sistema DoubleCheck, propuesto por Dong *et al.*, por su parte, detectó conducción con una sola mano mediante características en el dominio temporal y frecuencial junto con SVM, obteniendo un F1-score de 0.94 [14]. En conjunto, estos trabajos muestran que el *smartphone* puede soportar reconocimiento ligero y potencialmente ejecutable en tiempo real, pero también evidencian una sensibilidad notable a la posición del dispositivo, a su orientación y al ruido introducido por el propio usuario.

III-C. Sistemas con IMU montada o embebida en la bicicleta

La colocación dedicada de la IMU sobre la bicicleta resulta especialmente atractiva para sistemas IoT, porque reduce la variabilidad debida al usuario y mejora el acoplamiento entre la señal medida y la dinámica real del vehículo. Esta configuración es además la más transferible a un prototipo futuro basado en Arduino Nano 33 BLE.

La detección de frenada en bicicletas eléctricas fue abordada por Schnee *et al.*, quienes combinaron aceleración longitudinal filtrada, estimación de *pitch* y un modelo longitudinal de dinámica de bicicleta. Más que un clasificador convencional, el trabajo propone una detección funcional de frenada y muestra que el método detecta situaciones de frenado con el 50 % de la magnitud requerida por métodos umbral de referencia del estado del arte [15]. Este trabajo es uno de los más cercanos al objetivo de distinguir frenada suave y frenada fuerte en un prototipo práctico, aunque no reporta una exactitud o F1 global directamente comparable con el resto del corpus.

La monitorización de superficie y eventos de conducción con IMU embebida también ha madurado. Peng *et al.* integraron una IMU en el candado de una bicicleta compartida y emplearon LDA para clasificar asfalto, camino de piedra y superficie bacheada con un 95.3 % de exactitud en validación cruzada [6]. Jiang *et al.* ampliaron esta línea con una arquitectura de aprendizaje profundo de doble flujo y *meta-learning* que modela información temporal y frecuencial, reportando un 98.89 % de exactitud para condiciones del firme y un 99.58 % para eventos de conducción en un escenario convencional [5]. Además de su rendimiento, este estudio destaca por tratar explícitamente dos problemas muy relevantes para despliegue real: la generalización entre distintos tipos de bicicleta y la adaptación a nuevas clases con pocas muestras.

Esta línea se complementa con trabajos recientes más centrados en eventos o maniobras. El sistema BikeSense, propuesto por Mathuseck *et al.*, utilizó una bicicleta instrumentada y un clasificador basado en transformer para reconocer pedaleo, avance por inercia y frenada, alcanzando un F1 medio ponderado de 96.5 % [16]. Por su parte, la predicción de maniobras de giro con IMU montada en la bicicleta y CNN-LSTM alcanzó F1-score de 0.72 a 0.5 s antes del evento y 0.92 a 0.25 s [8]. En conjunto, estos resultados sugieren que el sensado fijo sobre la bicicleta es especialmente prometedor cuando el objetivo es un prototipo embebido compacto, ya que la interpretación de la señal se vincula de forma más directa con la dinámica de la bicicleta que con el movimiento corporal del ciclista.

La Tabla II presenta una comparación cuantitativa de los estudios más relevantes del corpus, cubriendo 17 trabajos individuales y evitando la agrupación de tareas o métricas no homogéneas.

III-D. Enfoques wearable y montados en casco

Un subconjunto más reducido de la literatura desplaza el punto de sensado desde la bicicleta hacia el cuerpo o el equipamiento del ciclista. El sistema HeadMon, propuesto por Han *et al.*, es el ejemplo más claro: monta una IMU en el casco y emplea una CNN-LSTM con atención para predecir maniobras a partir de la dinámica de la cabeza. El sistema reportó precisión de al menos el 85 % para horizontes de predicción de 4 s [7]. Este tipo de métodos es valioso porque persigue captar intención del ciclista en lugar de limitarse a la dinámica física de la bicicleta. Sin embargo, es menos directamente transferible a un prototipo montado sobre la bicicleta y añade nuevas dependencias, como colocación

correcta del casco, cumplimiento del usuario y variabilidad conductual.

III-E. Detección de near-miss y contexto amplio de seguridad

La detección de *near-miss* amplía la revisión más allá de los accidentes efectivamente ocurridos y conecta la seguridad ciclista con el análisis del riesgo urbano. El sistema CycleSense, propuesto por Karakaya *et al.* utiliza sensores de movimiento de smartphone y una combinación de procesamiento de señal y aprendizaje automático sobre el dataset SimRa, alcanzando un AUC-ROC de 0.906 [9]. Saleh *et al.* propusieron XceptionCycle, una red temporal ligera para detección de *near-miss*, con AUC-ROC del 81.99 % y reducción de parámetros frente a baselines más pesados [10]. Estos resultados son relevantes, pero no deben leerse como una comparación directa 1:1, ya que CycleSense reporta 0.906 en su protocolo original y XceptionCycle 0.8199 en su propia evaluación, con diferencias de preprocesado y configuración experimental.

IV. DISCUSIÓN

La principal conclusión del corpus revisado es que no existe todavía un único método basado en IMU que cubra, de forma unificada y bien validada, el conjunto completo de eventos más relevante para el prototipo objetivo: frenada suave, frenada fuerte, subida de bordillo, bajada de bordillo y lógica fiable de alarma ante accidente. En cambio, la literatura aparece fragmentada en subproblemas parcialmente solapados. La frenada se estudia explícitamente en trabajos de modelado montado en bicicleta [15]; la caída o el accidente se tratan en clasificadores con smartphone, MARG o sistemas IoT [1], [4], [17]; los eventos de bordillo, bache y rugosidad se abordan en artículos sobre daño del firme y monitorización de superficie [5], [6], [11], [12], [13]; y la predicción de maniobras o el reconocimiento de comportamiento se estudia con smartphone, IMU fija en bicicleta y sensores en casco [2], [3], [7], [8], [14], [16]. Esta fragmentación es, por sí misma, un resultado relevante del estado del arte.

Desde el punto de vista metodológico, la evidencia más sólida procede de trabajos que combinan una configuración de sensado realista, datasets suficientemente estructurados, métricas estándar y modelos adecuados para la naturaleza temporal de la señal IMU. En esta revisión, la evidencia más fuerte la proporcionan HeadMon, CycleSense y XceptionCycle, junto con varios estudios de calidad media pero muy sólidos desde la perspectiva aplicada, como los de Schnee *et al.*, Peng *et al.*, Jiang *et al.* y de Smit *et al.* [5], [6], [7], [8], [9], [10], [15]. En cambio, cuatro estudios fueron clasificados como de baja calidad o riesgo de sesgo elevado, principalmente por muestras limitadas, falta de baseline claro o escasa generalización. Sus resultados siguen siendo útiles como apoyo contextual, pero no deben utilizarse como base principal para decisiones de diseño.

La calidad se evaluó mediante ocho ítems: validación real, muestra suficiente, métricas estándar, baseline, protocolo reproducible, limitaciones declaradas, generalización y conflicto de interés. La Tabla III resume el reparto global de calidad del corpus incluido.

Tabla II
COMPARACIÓN DE LOS 17 ESTUDIOS INCLUIDOS EN LA REVISIÓN.

Ref.	Evento	Sensor/posición	Dataset/validación	Algoritmo	Métrica principal	Viabilidad temporal / IoT	Limitación
[1]	Accidente / eCall	Smartphone; GPS + acelerómetro + giroscopo	5.5 h de ciclismo normal + 6 crashes simulados	Heurístico CDA	6/6 accidentes; 0 falsos positivos	Viable; latencia N/D	Muestra pequeña y crashes simulados
[2]	Parada/recta/giro	Smartphone en manillar	Datos etiquetados de cuatro clases	Random Forest	F1-score $\approx 0,9$	Viable; latencia N/D	Validación limitada y dependencia del montaje
[3]	Conducción peligrosa	Smartphone + GPS	12 voluntarios; 54 vías; 2640 segmentos	SVM + transferencia	86.8 % / 90.0 % de exactitud	Reportada en móvil	Dependencia del teléfono y del usuario
[4]	Caída / accidente	MARG en manillar	34 ensayos; validación 5-fold	PCA + SVM	95.2 % exactitud; 96 % sensibilidad; 94 % especificidad	Viable; latencia N/D	Protocolo controlado y una sola bicicleta
[5]	Firme + eventos	IMU embebida en bicicleta compartida	Escenarios convencionales y de adaptación	Dual-stream DL + meta-learning	98.89 % / 99.58 % de exactitud	No reportada	Complejidad alta y necesidad de entrenamiento previo
[6]	Estado del firme	IMU en candado de bicicleta compartida	Dos bicicletas; validación cruzada	LDA	95.3 % de exactitud	Viable; latencia N/D	Solo tres clases de superficie
[7]	Predicción de maniobras	IMU en casco	20 participantes	CNN-LSTM con atención	≥ 85 % de precisión a 4 s	25 ms reportados	Menor transferibilidad a prototipo sobre bicicleta
[8]	Predicción de giro	IMU en bicicleta	20 participantes; 726 muestras	CNN-LSTM	F1 = 0.72 (0.5 s), 0.92 (0.25 s)	Predicción anticipada	Escenario controlado y pocas maniobras
[9]	Near-miss	Smartphone IMU + GPS	SimRa; >65 000 trayectos	Procesado de señal + ML	AUC-ROC = 0.906	No reportada en vivo	Etiquetas autoinformadas y fuerte heterogeneidad
[10]	Near-miss	Smartphone IMU + GPS	Evaluación propia sobre SimRa procesado	XceptionCycle	AUC-ROC = 0.8199	Potencial; latencia N/D	No directamente comparable con [9]
[11]	Daño del firme	Smartphone en bolsillo	50 ensayos por clase	ICA + FFT + umbrales	70.0 % de exactitud	No reportada	Diferenciación limitada entre tipos de daño
[12]	Baches / calidad del firme	Smartphone montado en bicicleta	Rutas ciclistas etiquetadas	Clasificador clásico	≈ 97 % en detección de bumps	<2 ms reportados	La clasificación global del firme es menos comparable
[13]	Rugosidad / baches / resaltos	Smartphone en bicicleta	3 experimentos; comparación instrumental	IRI + heurísticos	$r = 0,893$ con instrumento profesional	App móvil; latencia N/D	Métrica distinta del resto; depende de ruta y montaje
[14]	Conducción con una mano	Smartphone en manillar	10 participantes; 40 322 segmentos	SVM	F1 = 0.94	Ventanas de 0,5 s	No incorpora velocidad ni otros riesgos
[15]	Frenada	IMU en bicicleta + modelo dinámico	Escenarios de prueba en e-bike	Modelo físico + umbrales	Detecta frenadas con 50 % de la magnitud requerida por métodos umbral de referencia	Respuesta rápida; latencia N/D	No reporta exactitud/F1 global comparable
[16]	Pedaleo / inercia / frenada	Bicicleta instrumentada; varias posiciones	Pista recta; 15 recorridos ida y vuelta	Transformer	F1-score medio = 96.5 %	Online; latencia N/D	Una bicicleta y superficie uniforme
[17]	Caída / alerta IoT	WT901 + ESP8266 / bicicleta	96 ensayos + prueba en tiempo real	PCA + SVM cuadrática	99.05 % de exactitud	Reportada; vía nube	Entorno controlado y fuerte dependencia del protocolo

Tabla III
RESUMEN DE CALIDAD DE LOS 17 ESTUDIOS INCLUIDOS.

Categoría de calidad	Número de estudios
Alta	3
Media	10
Baja	4

Una segunda observación clave está relacionada con el realismo de despliegue. Los enfoques basados exclusivamente en smartphone son atractivos porque reducen la barrera de adopción, pero también son los más sensibles a la posición, la orientación y el ruido introducido por el usuario. Esto afecta tanto a la reproducibilidad como a la generalización. En

cambio, las IMU montadas o embebidas en la bicicleta parecen más adecuadas para un sistema IoT dedicado, porque ofrecen una geometría de sensado más estable y se integran mejor en un pipeline determinista de procesamiento. Esto es especialmente importante para un prototipo basado en Arduino Nano 33 BLE, donde el presupuesto de memoria y cómputo es limitado y donde una colocación fija del sensor simplifica la calibración y la adaptación de umbrales. En este sentido, los estudios más directamente transferibles al objetivo del proyecto son los centrados en sensado montado en la bicicleta para frenada, comportamiento y maniobras [2], [8], [15], [16].

La revisión también deja ver varios vacíos recurrentes. En primer lugar, no existe un benchmark público que cubra de forma conjunta múltiples clases de evento ciclista bajo una

misma taxonomía, una posición de sensor consistente y un protocolo homogéneo de evaluación. En segundo lugar, la generalización entre bicicletas y entre ciclistas sigue poco explorada, a pesar de ser esencial para un despliegue real. En tercer lugar, muchos artículos reportan buenos valores de clasificación en condiciones controladas, pero ofrecen poca información sobre falsas alarmas en circulación urbana real. En cuarto lugar, la lógica de alerta por accidente se valida con frecuencia sobre caídas simuladas, no sobre incidentes naturalistas. Finalmente, la comparabilidad entre estudios es limitada no solo por la diversidad de tareas, sino también por la coexistencia de métricas distintas —exactitud, F1-score, AUC, sensibilidad, especificidad o correlación— y por diferencias importantes en tamaño de dataset, protocolo de etiquetado y ubicación del sensor.

Como fortaleza metodológica, la revisión siguió un protocolo explícito basado en PICOS, documentó un proceso de selección compatible con PRISMA e incorporó una evaluación de calidad que permitió ponderar la evidencia en lugar de tratar todos los trabajos como equivalentes. Como limitación principal, el corpus sigue siendo heterogéneo y una parte de la evidencia más favorable procede de escenarios controlados o de caídas simuladas. Por ello, las conclusiones deben interpretarse como una síntesis crítica del mejor conocimiento disponible, no como una comparación experimental directa entre todos los métodos.

Para el sistema objetivo de este proyecto, la literatura sugiere una estrategia pragmática. Una primera implementación puede apoyarse en una IMU montada de forma fija sobre la bicicleta y en características extraídas en ventanas temporales de acelerómetro y giróscopo para distinguir, al menos, frenadas y eventos verticales tipo bordillo, mediante una SVM ligera o un clasificador temporal compacto inspirado en los mejores estudios revisados. Una alarma ante evento severo podría construirse encima de ese clasificador combinando alta deceleración, cambio brusco de orientación y persistencia del evento, en lugar de depender únicamente de un umbral simple de aceleración. La literatura sobre *near-miss* y dinámica de cabeza es menos transferible de forma directa a un primer prototipo, pero ofrece una hoja de ruta para extensiones futuras una vez que el detector básico de eventos sea operativo.

V. CONCLUSIONES

Esta revisión sistemática analizó 17 estudios sobre detección en tiempo real de eventos de conducción en bicicleta basada en IMU, incluyendo configuraciones con smartphone, sensado montado o embebido en la bicicleta y enfoques *wearable*. La literatura muestra que el sensado inercial ya es capaz de reconocer con resultados prometedores varias familias de eventos relevantes, como frenadas, maniobras, caídas, *near-miss* y anomalías del firme. Sin embargo, la evidencia está distribuida entre tareas específicas y todavía no existe un benchmark unificado ni una taxonomía común que permita una comparación directa y robusta entre todos los enfoques.

Si se consideran conjuntamente capacidad de clasificación, viabilidad práctica y relevancia para un prototipo IoT de seguridad, los enfoques más adecuados son los sistemas con

IMU montada o embebida en la bicicleta combinados con clasificadores compactos basados en características o con modelos temporales ligeros. Los sistemas apoyados solo en smartphone siguen siendo útiles para prototipado rápido y recogida de datos, pero suelen ser más vulnerables a variabilidad de posición y a ruido introducido por el usuario. Los métodos *wearable* o montados en casco son prometedores para predicción de intención, pero menos alineados con una primera demo embebida directamente sobre la bicicleta.

En síntesis, la opción más adecuada para el problema PICOS planteado es una IMU montada de forma fija en la bicicleta, combinada con un pipeline ligero de características temporales y un clasificador compacto o modelo temporal poco costoso, capaz de ofrecer detección fiable, baja latencia y viabilidad real de despliegue en una plataforma IoT embebida. El siguiente paso más razonable no es reproducir el sistema más amplio de la literatura, sino implementar una taxonomía de eventos estrecha y robusta, centrada en frenada, transiciones tipo bordillo y lógica de alarma ante evento severo, dejando preparada la canalización de datos para incorporar en el futuro maniobras más complejas y analítica de seguridad más rica.

AGRADECIMIENTOS

El autor utilizó herramientas de inteligencia artificial como apoyo durante las fases de planificación de búsqueda, apoyo a la extracción de datos y revisión lingüística del borrador. La selección final de estudios, la interpretación de los resultados y las conclusiones fueron revisadas manualmente y son responsabilidad del autor.

REFERENCIAS

- [1] S. Candefjord et al., «Using Smartphones to Monitor Cycling and Automatically Detect Accidents — Towards eCall Functionality for Cyclists,» in *Proceedings of the International Cycling Safety Conference*, Göteborg, Sweden, 2014.
- [2] Y. Usami, K. Ishikawa, T. Takayama, M. Yanagisawa y N. Togawa, «Bicycle Behavior Recognition Using Sensors Equipped with Smartphone,» in *2018 IEEE 8th International Conference on Consumer Electronics – Berlin (ICCE-Berlin)*, IEEE, 2018.
- [3] W. Gu et al., «BikeMate: Bike Riding Behavior Monitoring with Smartphones,» in *Proceedings of the 14th EAI International Conference on Mobile and Ubiquitous Systems: Computing, Networking and Services*, 2017. DOI: 10.1145/3144457.3144462.
- [4] F. Tabei, B. Askarian y J. W. Chong, «Accident Detection System for Bicycle Riders,» *IEEE Sensors Journal*, vol. 21, no. 2, pp. 878-885, 2021. DOI: 10.1109/JSEN.2020.3021652.
- [5] S. Jiang, Z. Strout, B. He, D. Peng, P. B. Shull y B. P. L. Lo, «Dual Stream Meta Learning for Road Surface Classification and Riding Event Detection on Shared Bikes,» *IEEE Transactions on Systems, Man, and Cybernetics: Systems*, vol. 53, no. 11, pp. 7188-7200, 2023. DOI: 10.1109/TSMC.2023.3295424.

- [6] D. Peng, Z. Strout, S. Jiang y P. B. Shull, «A Road Condition Classifier via Lock Embedded IMU on Dock-Less Shared Bikes,» in *Proceedings of the International Conference on Networking, Sensing and Embedded Research*, 2019. DOI: 10.1145/3333581.3333597.
- [7] Z. Han, L. Xu, X. Dong, Y. Nishiyama y K. Sezaki, «HeadMon: Head Dynamics Enabled Riding Maneuver Prediction,» in *2023 IEEE International Conference on Pervasive Computing and Communications (PerCom)*, IEEE, 2023. DOI: 10.1109/PERCOM56429.2023.10099215.
- [8] G. de Smit, D. Yeleshetty, P. J. M. Havinga e Y. Huang, «Predicting Turn Maneuvers of Cyclists Using Bicycle-Mounted IMU with CNN-LSTM,» in *2024 IEEE International Conference on Pervasive Computing and Communications Workshops and Other Affiliated Events (PerCom Workshops)*, PERVEHICLE Workshop, IEEE, 2024. DOI: 10.1109/PerComWorkshops59983.2024.10502681.
- [9] A.-S. Karakaya, T. Ritter, F. Biessmann y D. Bermbach, «CycleSense: Detecting Near Miss Incidents in Bicycle Traffic from Mobile Motion Sensors,» *Pervasive and Mobile Computing*, vol. 91, p. 101779, 2023. DOI: 10.1016/j.pmcj.2023.101779.
- [10] K. Saleh, A. Grigorev y A.-S. Mihaita, «Cyclist Near-Miss Detection Using Lightweight Deep Temporal Neural Networks,» in *2025 IEEE 28th International Conference on Intelligent Transportation Systems (ITSC)*, IEEE, 2025. DOI: 10.1109/ITSC60802.2025.11423617.
- [11] Y. Kobana, Y. Tobe, J. Takahashi, G. Lopez y N. Kitsunozaki, «Detection of Road Damage Using Signals of Smartphone-Embedded Accelerometer While Cycling,» in *Proceedings of the International Workshop on Web Intelligence and Smart Sensing*, 2014. DOI: 10.1145/2637064.2637107.
- [12] M. Hoffmann, M. Mock y M. May, «Road-Quality Classification and Bump Detection with Bicycle-Mounted Smartphones,» in *Proceedings of the 3rd International Workshop on Ubiquitous Data Mining*, 2013.
- [13] K. Zang, J. Shen, H. Huang, M. Wan y J. Shi, «Assessing and Mapping of Road Surface Roughness Based on GPS and Accelerometer Sensors on Bicycle-Mounted Smartphones,» *Sensors*, vol. 18, no. 3, p. 914, 2018. DOI: 10.3390/s18030914.
- [14] X. Dong, Z. Han, Y. Nishiyama y K. Sezaki, «DoubleCheck: Detecting Single-Hand Cycling with Inertial Measurement Unit of Smartphone,» in *2022 IEEE International Conference on Pervasive Computing and Communications Workshops and Other Affiliated Events (PerCom Workshops)*, IEEE, 2022. DOI: 10.1109/PerComWorkshops53856.2022.9767429.
- [15] J. Schnee, J. Stegmaier, T. Lipowsky y P. Li, «Brake Detection for Electric Bicycles Using Inertial Measurement Units,» in *2019 IEEE Sensors Applications Symposium (SAS)*, IEEE, 2019.
- [16] L. Mathuseck, J. Götz, L. Busch y K. David, «BikeSense: Riding Behaviour Recognition Using an Instrumented Bicycle,» in *2024 IEEE International Conference on Pervasive Computing and Communications Workshops and Other Affiliated Events (PerCom Workshops)*, CoMoRea Workshop, IEEE, 2024. DOI: 10.1109/PerComWorkshops59983.2024.10503127.
- [17] P. M. Alcaide, K. D. Finez y G. V. Magwili, «Real-time Monitoring of Bicycle Behavior in IoT Fall Detection System,» in *2024 8th International Conference on Communication and Information Systems (ICCIS)*, IEEE, 2024. DOI: 10.1109/ICCIS63642.2024.10779382.